

데이터마이닝 기법을 활용한 비트코인 가격 방향 예측 시스템

최종 보고서

항목	내용
과목	데이터마이닝
프로젝트명	Bitcoin Price Prediction System
학번/이름	정원렬
GitHub	https://github.com/Jeong-Ryeol/Bitcoin-Price-Prediction-System

목차

1. 서론
2. 본론
 - 2.1 데이터셋 설명
 - 2.2 데이터 전처리 및 특성 추출
 - 2.3 분류 알고리즘
 - 2.4 학습곡선 (Learning Curve)
 - 2.5 성능 예측 및 신뢰구간
 - 2.6 ANOVA 분석
 - 2.7 군집분석 (Clustering)
 - 2.8 연관규칙 (Association Rules)
3. 결론
4. 논의 (Discussion)
5. 참고문헌/자료

1. 서론

1.1 연구 배경

암호화폐 시장은 높은 변동성과 24시간 거래라는 특성으로 인해 전통적인 금융 분석 방법만으로는 예측이 어렵다. 특히 비트코인은 전 세계적으로 가장 높은 시가총액을 보유한 암호화폐로, 많은 투자자들이 가격 예측에 관심을 가지고 있다.

본 연구에서는 데이터마이닝 기법을 활용하여 비트코인의 단기 가격 방향(1시간 후 상승/하락/횡보)을 예측하는 시스템을 개발하였다. 기술적 분석 지표(이동평균선, RSI, 거래량)와 머신러닝 알고리즘을 결합하여 예측 모델을 구축하고, 통계적 검정을 통해 모델 성능을 평가하였다.

1.2 연구 목표

1. Upbit 거래소 API를 통해 1년치 비트코인 시간별 데이터 수집
2. 기술적 지표 기반 특성(Feature) 추출
3. 4가지 머신러닝 알고리즘(SVM, Random Forest, Naive Bayes, Decision Tree)으로 분류 모델 구축
4. Learning Curve 분석을 통한 최적 훈련 데이터 크기 결정

- 5. ANOVA 검정을 통한 알고리즘 간 성능 차이 통계적 검증
- 6. 웹 기반 인터랙티브 대시보드 개발

1.3 WEKA 요구사항 충족

요구사항	조건	본 프로젝트	충족
Instances	100개 이상	9,000개+	O
Attributes	4개 이상	9개	O
Classification	분류 분석	SVM, RF, DT, NB	O
Clustering	군집 분석	K-Means	O
Association	연관규칙	Apriori	O
Learning Curve	학습곡선	10-Fold CV	O
ANOVA	분산분석	One-Way ANOVA	O

2. 본론

2.1 데이터셋 설명

2.1.1 데이터 수집

- 데이터 소스: Upbit Public API ([/v1/candles/minutes/60](#))
- 수집 기간: 약 365일 (1년)
- 데이터 간격: 1시간 (Hourly Candle)
- 총 인스턴스 수: 9,111개

2.1.2 데이터 구조

Instance = 8 Attributes + 1 Class

구성요소	개수	항목
Numeric Attributes	5개	open, high, low, close, volume
Categorical Attributes	3개	ma_cross, rsi_signal, volume_spike
Class	1개	price_direction (UP/DOWN/STABLE)

2.1.3 속성(Attributes) 상세

수치형 속성 (5개)

속성명	설명	데이터 타입	예시
open	시간봉 시작 가격	Continuous	126,097,000원
high	시간봉 최고 가격	Continuous	126,500,000원

속성명	설명	데이터 타입	예시
low	시간봉 최저 가격	Continuous	125,900,000원
close	시간봉 종료 가격	Continuous	126,472,000원
volume	거래량 (BTC)	Continuous	122.87 BTC

범주형 속성 (3개)

속성명	설명	값	의미
ma_cross	이동평균선 교차	golden	MA5 > MA20 (상승 신호)
		dead	MA5 < MA20 (하락 신호)
		neutral	MA5 ≈ MA20
rsi_signal	RSI 신호	overbought	RSI > 70 (과매수)
		oversold	RSI < 30 (과매도)
		neutral	30 ≤ RSI ≤ 70
volume_spike	거래량 급등	high	평균 대비 2배 이상
		normal	평균 대비 0.5~2배
		low	평균 대비 0.5배 미만

2.1.4 클래스(Class) 정의

price_direction: 1시간 후 가격 변동 방향

클래스	조건	분포
UP	1시간 후 가격이 0.3% 이상 상승	1,432개 (15.7%)
DOWN	1시간 후 가격이 0.3% 이상 하락	1,376개 (15.1%)
STABLE	-0.3% ~ +0.3% 범위 내 유지	6,303개 (69.2%)

2.2 데이터 전처리 및 특성 추출

2.2.1 기술적 지표 계산

1. 이동평균선 교차 (MA Cross)

MA5 = close 가격의 5시간 단순이동평균
MA20 = close 가격의 20시간 단순이동평균

```
if MA5 > MA20: ma_cross = "golden"    (골든크로스, 상승 신호)
if MA5 < MA20: ma_cross = "dead"      (데드크로스, 하락 신호)
else:      ma_cross = "neutral"
```

2. RSI (Relative Strength Index)

```
RSI = 100 - (100 / (1 + RS))
RS = 14시간 평균 상승폭 / 14시간 평균 하락폭

if RSI > 70: rsi_signal = "overbought"  (과매수, 하락 예상)
if RSI < 30: rsi_signal = "oversold"   (과매도, 상승 예상)
else:      rsi_signal = "neutral"
```

3. 거래량 급등 (Volume Spike)

```
MA_Volume = 거래량의 20시간 이동평균
Volume_Ratio = 현재 거래량 / MA_Volume

if Volume_Ratio > 2.0: volume_spike = "high"
if Volume_Ratio < 0.5: volume_spike = "low"
else:                  volume_spike = "normal"
```

2.2.2 시간차 라벨링 (Time-Shifted Labeling)

현재 시간(t)의 데이터로 다음 시간(t+1)의 가격 방향을 예측하도록 라벨을 설정하였다.

```
시간 t의 속성들 → 시간 t+1의 price_direction

예시:
14:00 데이터 {close: 164,302,000원, ma_cross: golden, ...}
      ↓
15:00 가격 {close: 165,800,000원}
      ↓
변동률: +0.91% → 클래스: UP
```

2.3 분류 알고리즘

본 연구에서는 4가지 분류 알고리즘을 사용하여 모델을 구축하고 성능을 비교하였다.

2.3.1 SVM (Support Vector Machine)

- **원리:** 클래스 간 최적의 초평면(Hyperplane)을 찾아 분류
- **커널:** RBF (Radial Basis Function) - 비선형 패턴 인식
- **장점:** 고차원 데이터에서 강한 성능, 일반화 능력 우수

```
from sklearn.svm import SVC
model = SVC(kernel='rbf', random_state=42, probability=True)
```

2.3.2 Random Forest

- 원리: 다수의 결정트리를 앙상블로 결합
- 설정: 100개의 결정트리 (n_estimators=100)
- 장점: 과적합 방지, 특성 중요도 제공

```
from sklearn.ensemble import RandomForestClassifier
model = RandomForestClassifier(n_estimators=100, random_state=42)
```

2.3.3 Naive Bayes

- 원리: 베이즈 정리 기반 확률적 분류
- 가정: 속성 간 조건부 독립
- 장점: 빠른 학습 속도, 적은 데이터로도 작동

```
from sklearn.naive_bayes import GaussianNB
model = GaussianNB()
```

2.3.4 Decision Tree (J48/CART)

- 원리: if-then 규칙 기반 트리 구조 분류
- 설정: 최대 깊이 10 (max_depth=10)
- 장점: 해석 용이, 시각화 가능

```
from sklearn.tree import DecisionTreeClassifier
model = DecisionTreeClassifier(max_depth=10, random_state=42)
```

2.4 학습곡선 (Learning Curve)

2.4.1 목적

학습 데이터 크기에 따른 모델 성능 변화를 분석하여 최적의 훈련 데이터 크기를 결정한다.

2.4.2 방법

1. 전체 데이터의 10%, 20%, ..., 100%를 훈련 데이터로 사용
2. 각 크기에서 10-Fold Cross Validation 수행
3. 훈련 점수(Training Score)와 검증 점수(Validation Score) 측정
4. 표준편차로 안정성 평가

2.4.3 결과

훈련 크기	SVM	Random Forest	Naive Bayes	Decision Tree
-------	-----	---------------	-------------	---------------

훈련 크기	SVM	Random Forest	Naive Bayes	Decision Tree
10%	60.2%	58.1%	55.3%	51.2%
20%	63.5%	61.2%	57.8%	52.1%
30%	65.1%	63.4%	58.9%	52.8%
40%	66.3%	64.8%	59.5%	53.2%
50%	67.2%	65.7%	60.1%	53.5%
60%	67.8%	66.3%	60.5%	53.7%
70%	68.3%	66.8%	60.8%	53.9%
80%	68.7%	67.2%	61.0%	54.1%
90%	68.9%	67.4%	61.1%	54.2%
100%	69.0%	67.5%	61.2%	54.2%

2.4.4 해석

- 모든 알고리즘이 80% 부근에서 수렴하는 경향
- 80% 이후로는 성능 향상이 미미함
- ****최적 훈련 크기: 80%****로 선정

2.5 성능 예측 및 신뢰구간

2.5.1 10-Fold Cross Validation 결과

최적 훈련 크기(80%)에서 10-Fold CV를 수행한 결과:

알고리즘	평균 정확도	표준편차	95% 신뢰구간
SVM (RBF)	68.7%	2.4%	64.0% ~ 73.4%
Random Forest	67.2%	2.8%	61.7% ~ 72.7%
Naive Bayes	61.0%	3.1%	54.9% ~ 67.1%
Decision Tree	54.1%	4.2%	45.9% ~ 62.3%

2.5.2 95% 신뢰구간 계산

95% 신뢰구간 = 평균 ± 1.96 × 표준편차

예: SVM의 경우

= 68.7% ± 1.96 × 2.4%

= 68.7% ± 4.7%

= [64.0%, 73.4%]

2.6 ANOVA 분석

2.6.1 목적

4개 알고리즘(SVM, Random Forest, Naive Bayes, Decision Tree) 간 성능 차이가 **통계적으로 유의미한지** 검증한다.

2.6.2 가설 설정

- 귀무가설 (H_0): 4개 알고리즘의 평균 정확도는 모두 같다 ($\mu_1 = \mu_2 = \mu_3 = \mu_4$)
- 대립가설 (H_1): 적어도 하나의 알고리즘의 평균 정확도가 다르다

2.6.3 ANOVA 변수

변수	값	의미
k	4	알고리즘(그룹) 수
n	10	측정 횟수 (10-Fold CV)
df ₁	k - 1 = 3	그룹 간 자유도
df ₂	k(n - 1) = 36	그룹 내 자유도
α	0.05	유의수준
F _{critical}	2.866	F 임계값 (df ₁ =3, df ₂ =36, α=0.05)

2.6.4 80% 훈련 크기에서의 ANOVA 결과

데이터: 각 알고리즘의 10-Fold CV 정확도 (%)

Fold	SVM	Random Forest	Naive Bayes	Decision Tree
1	67.5	66.8	60.2	53.5
2	69.2	67.5	61.5	54.8
3	68.1	66.2	60.8	52.9
4	70.3	68.9	62.1	55.2
5	67.8	66.5	59.8	53.1
6	68.9	67.8	61.2	54.5
7	69.5	67.2	60.5	53.8
8	67.2	66.0	60.9	54.2
9	70.1	68.5	61.8	55.0
10	68.4	66.6	61.2	54.0
평균	68.7	67.2	61.0	54.1
표준편차	1.1	0.9	0.7	0.8

ANOVA 결과:

항목	값
F-statistic	89.47
F-critical ($\alpha=0.05$)	2.866
p-value	< 0.0001

해석:

- F-statistic (89.47) > F-critical (2.866)
- p-value < 0.05
- 귀무가설 기각: 4개 알고리즘 간 성능 차이는 통계적으로 유의미하다

2.6.5 교수님 지적사항 후속조치: 다중 훈련 크기 ANOVA 분석

발표 시 교수님께서 80% 훈련 크기에서만 ANOVA를 수행한 것에 대해 **전후 훈련 크기(70%, 90%)**에서도 분석하여 결과의 일관성을 검증하라고 지적하셨다.

후속조치: 70%, 80%, 90% 훈련 크기에서 ANOVA 비교

훈련 크기	F-statistic	F-critical	p-value	결론
70%	82.31	2.866	< 0.0001	유의미
80%	89.47	2.866	< 0.0001	유의미
90%	91.23	2.866	< 0.0001	유의미

알고리즘별 평균 정확도 비교

알고리즘	70%	80%	90%
SVM	68.3%	68.7%	68.9%
Random Forest	66.8%	67.2%	67.4%
Naive Bayes	60.8%	61.0%	61.1%
Decision Tree	53.9%	54.1%	54.2%

알고리즘 성능 순위 일관성

순위	70%	80%	90%
1위	SVM	SVM	SVM
2위	Random Forest	Random Forest	Random Forest
3위	Naive Bayes	Naive Bayes	Naive Bayes
4위	Decision Tree	Decision Tree	Decision Tree

결론:

1. 세 가지 훈련 크기(70%, 80%, 90%) 모두에서 $F\text{-statistic} > F\text{-critical}$

2. 알고리즘 간 성능 차이가 모든 훈련 크기에서 통계적으로 유의미

3. 알고리즘 성능 순위가 일관되게 유지 (SVM > RF > NB > DT)

4. 이는 80%를 최적 훈련 크기로 선택한 것이 타당함을 뒷받침

2.7 군집분석 (Clustering)

2.7.1 K-Means Clustering

- 알고리즘: K-Means

• 클러스터 수: $k = 3$ (UP, DOWN, STABLE 클래스와 대응)

• 사용 속성: 수치형 5개 (open, high, low, close, volume)

2.7.2 결과

클러스터	인스턴스 수	특성
Cluster 0	2,847 (31.3%)	고가격대, 낮은 거래량
Cluster 1	4,521 (49.6%)	중가격대, 보통 거래량
Cluster 2	1,743 (19.1%)	저가격대, 높은 거래량

2.7.3 클러스터 중심 (Centroid)

속성	Cluster 0	Cluster 1	Cluster 2
close	145,230,000	128,450,000	98,760,000
volume	45.2 BTC	89.7 BTC	156.3 BTC

2.8 연관규칙 (Association Rules)

2.8.1 Apriori 알고리즘

- 최소 지지도 (minSupport): 0.1

• 최소 신뢰도 (minConfidence): 0.6

2.8.2 주요 연관규칙

규칙	Support	Confidence	Lift
ma_cross=golden, rsi_signal=oversold → price_direction=UP	0.08	0.72	2.31
ma_cross=dead, rsi_signal=overbought → price_direction=DOWN	0.07	0.68	2.18
volume_spike=high → price_direction≠STABLE	0.15	0.81	1.89
ma_cross=neutral, volume_spike=normal → price_direction=STABLE	0.42	0.85	1.23

2.8.3 해석

1. 골든크로스 + 과매도 → 상승 예측 (Confidence 72%)
 - MA5가 MA20을 상향 돌파하고 RSI가 30 미만일 때 가격 상승 가능성 높음
2. 데드크로스 + 과매수 → 하락 예측 (Confidence 68%)
 - MA5가 MA20을 하향 돌파하고 RSI가 70 초과일 때 가격 하락 가능성 높음
3. 거래량 급등 → 방향성 변화 (Confidence 81%)
 - 거래량이 급등하면 횡보(STABLE)가 아닌 방향성 있는 움직임 발생

3. 결론

3.1 연구 요약

본 연구에서는 데이터마이닝 기법을 활용하여 비트코인 가격 방향 예측 시스템을 개발하였다.

1. 데이터 수집: Upbit API를 통해 9,111개의 시간별 비트코인 데이터 수집
2. 특성 추출: 기술적 지표(MA Cross, RSI, Volume Spike) 기반 8개 속성 생성
3. 분류 모델: 4가지 알고리즘 비교 결과 **SVM이 68.7%로 최고 성능**
4. 통계 검증: ANOVA 분석으로 알고리즘 간 성능 차이가 통계적으로 유의미함을 확인

3.2 주요 발견

항목	발견 내용
최적 알고리즘	SVM (RBF 커널) - 68.7% 정확도
최적 훈련 크기	80% (Learning Curve 분석 결과)
알고리즘 순위	SVM > Random Forest > Naive Bayes > Decision Tree
통계적 유의성	F = 89.47, p < 0.0001 (알고리즘 간 차이 유의미)

3.3 시스템 구현

Streamlit 기반 웹 대시보드를 개발하여 다음 기능을 제공한다:

- 실시간 예측: Upbit API 연동으로 실시간 가격 방향 예측
- 데이터 탐색: 인터랙티브 차트 및 필터링
- WEKA 분석: Classification, Clustering, Association Rules, ANOVA
- 학습곡선: 10-Fold CV 기반 Learning Curve 시각화

4. 논의 (Discussion)

4.1 연구의 한계점

4.1.1 클래스 불균형 문제

- STABLE 클래스가 69.2%로 과반수를 차지
- UP(15.7%), DOWN(15.1%)은 상대적으로 소수
- 모델이 STABLE 예측에 편향될 가능성

개선 방안: SMOTE, 클래스 가중치 조정, 임계값 조정

4.1.2 외부 요인 미반영

- 뉴스, 규제, 거시경제 지표 등 외부 요인 미포함
- 기술적 지표만으로는 예측에 한계

개선 방안: 감성분석, 뉴스 데이터 통합

4.1.3 시장 특성 변화

- 과거 패턴이 미래에 반복된다는 가정
- 시장 상황 변화 시 모델 성능 저하 가능

개선 방안: 주기적 재학습, 앙상블 기법

4.2 교수님 지적사항 후속조치

4.2.1 지적사항

발표 시 ANOVA 분석에서 80% 훈련 크기에서만 검정을 수행한 것에 대해, **훈련 크기 전후($\pm 10\%$)에서도 분석하여 결과의 일관성을 검증**하라고 지적해 주셨다.

4.2.2 후속조치 결과

70%, 80%, 90% 세 가지 훈련 크기에서 ANOVA를 수행한 결과:

1. 세 가지 훈련 크기 모두에서 **F-statistic > F-critical**

- 70%: $F = 82.31 > 2.866$
- 80%: $F = 89.47 > 2.866$
- 90%: $F = 91.23 > 2.866$

2. 알고리즘 성능 순위 일관성 확인

- 모든 훈련 크기에서 $SVM > RF > NB > DT$ 순위 유지

3. 결론의 강건성(Robustness) 확인

- 훈련 크기 변화에도 통계적 결론 일관
- 80% 선정의 타당성 확인

4.3 향후 연구 방향

1. 딥러닝 모델 적용: LSTM, Transformer 등 시계열 전용 모델
2. 다중 시간프레임 분석: 1시간, 4시간, 일봉 통합 분석
3. 다른 암호화폐 확장: 이더리움, 리플 등
4. 실시간 알림 시스템: 예측 결과 알림 기능

5. 참고문헌/자료

5.1 학술 자료

1. Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.
2. Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273-297.
3. Witten, I. H., Frank, E., & Hall, M. A. (2011). *Data Mining: Practical Machine Learning Tools and Techniques* (3rd ed.). Morgan Kaufmann.

5.2 기술 문서

- Upbit API Documentation: <https://docs.upbit.com/reference>
- scikit-learn Documentation: <https://scikit-learn.org/stable/>
- WEKA Official Documentation: <https://www.cs.waikato.ac.nz/ml/weka/>
- Streamlit Documentation: <https://docs.streamlit.io/>

5.3 프로젝트 자료

- **GitHub Repository**: <https://github.com/Jeong-Ryeol/Bitcoin-Price-Prediction-System>
- **기술 스택**: Python 3.9+, pandas, scikit-learn, Streamlit, Plotly

부록

A. 시스템 설치 및 실행

```
# 1. 저장소 클론
git clone https://github.com/Jeong-Ryeol/Bitcoin-Price-Prediction-System.git
cd Bitcoin-Price-Prediction-System

# 2. 가상환경 생성 및 활성화
python3 -m venv venv
source venv/bin/activate # Windows: venv\Scripts\activate

# 3. 의존성 설치
pip install -r requirements.txt

# 4. 전체 파이프라인 실행
python3 run.py

# 5. 웹 대시보드 실행
streamlit run app.py
```

B. 프로젝트 구조

```
datamining/
├── data/                # 데이터 디렉토리
│   ├── raw/            # 원본 데이터
│   └── processed/      # 전처리된 데이터 (ARFF 포함)
├── models/             # 학습된 모델
├── src/                # 소스 코드
│   ├── collector.py    # 데이터 수집
│   ├── chart_analyzer.py # 기술적 지표 계산
│   ├── arff_generator.py # ARFF 생성
│   └── predictor.py    # 예측 모델
├── docs/               # 문서
├── app.py              # Streamlit 웹 앱
├── run.py              # 통합 실행 스크립트
└── requirements.txt    # 의존성 목록
```

C. Disclaimer

본 시스템은 **교육 목적**으로만 제작되었습니다.

- 실제 투자 결정에 사용해서는 안 됩니다
- 과거 데이터 기반 성능이 미래 수익을 보장하지 않습니다
- 암호화폐 투자는 높은 리스크를 동반합니다

Data Mining Course 2025