

Bitcoin Price Prediction System

데이터마이닝 기법을 활용한 비트코인 가격 방향 예측

Team Project - Data Mining 2025

GitHub: <https://github.com/Jeong-Ryeol/Bitcoin-Price-Prediction-System>

목차

- 1. Project Overview
- 2. Data Structure
- 3. Features Guide
- 4. Data Mining Methods
- 5. Installation & Academic Purpose

1. Project Overview

프로젝트 개요

비트코인 가격 예측 시스템은 **데이터마이닝 기법**을 활용하여 암호화폐 시장의 가격 방향을 예측하는 머신러닝 프로젝트입니다.

프로젝트 목표

- Upbit Public API를 통해 **1년치 시간별 데이터**를 수집
- 기술적 지표를 분석하여 **4가지 머신러닝 알고리즘**으로 가격 방향 예측
- **WEKA** 스타일 데이터마이닝 분석을 웹에서 구현

Dataset Statistics

항목	값
Total Instances	9,000개+
Total Attributes	9개 (8 features + 1 class)
Data Period	약 365일
Data Interval	1시간 (Hourly Candle)
Data Source	Upbit API

Technology Stack

Category	Technologies
----------	--------------

Category	Technologies
Data Collection	Upbit Public API (RESTful)
Data Processing	pandas, numpy
Technical Analysis	pandas-ta, RSI, Moving Average
Machine Learning	scikit-learn (SVM, RF, DT, NB)
Statistical Analysis	scipy (ANOVA)
Data Mining	mlxtend (Apriori), K-Means
Visualization	Streamlit, Plotly

2. Data Structure

Instance = Attribute + Class

구성요소	개수	항목
Attributes	8개	open, high, low, close, volume, ma_cross, rsi_signal, volume_spike
Class	1개	price_direction

Attributes (속성) - 8개

Numeric Attributes (수치형) - 5개

Attribute	Description	Type	Example
open	시간봉 시작 가격	Continuous	126,097,000 원
high	시간봉 최고 가격	Continuous	126,500,000 원
low	시간봉 최저 가격	Continuous	125,900,000 원
close	시간봉 종료 가격	Continuous	126,472,000 원
volume	거래량 (BTC)	Continuous	122.87 BTC

Categorical Attributes (범주형) - 3개

Attribute	Description	Values
ma_cross	이동평균선 교차 신호	golden, dead, neutral
rsi_signal	RSI 과매수/과매도 신호	overbought, oversold, neutral
volume_spike	거래량 급등/급락 신호	high, normal, low

Class (클래스) - 1개

Class	Description	Threshold
price_direction	1시간 후 가격 방향	UP/DOWN/STABLE

분류 기준:

- **UP**: 1시간 후 가격이 0.3% 이상 상승
- **DOWN**: 1시간 후 가격이 0.3% 이상 하락
- **STABLE**: -0.3% ~ +0.3% 범위 내 유지

Technical Indicators 상세

1. MA Cross (Moving Average Crossover)

- 단기 이동평균(5시간)과 장기 이동평균(20시간) 비교
- **Golden Cross**: MA5 > MA20 (상승 신호)
- **Dead Cross**: MA5 < MA20 (하락 신호)

2. RSI Signal (Relative Strength Index)

- 14시간 기준 상대강도지수
- **Overbought**: RSI > 70 (과매수 → 하락 예상)
- **Oversold**: RSI < 30 (과매도 → 상승 예상)

3. Volume Spike

- 20시간 평균 거래량 대비 비율
- **High**: 2배 이상 (급등)
- **Low**: 0.5배 이하 (급락)

3. Features Guide

각 페이지 기능 설명

1. Dashboard

목적: 데이터셋 전체 개요 및 통계 확인

주요 기능:

- 총 인스턴스 수, 속성 수, 데이터 기간 표시
- 비트코인 가격 시계열 차트 (Plotly Interactive)
- 클래스(UP/DOWN/STABLE) 분포 파이 차트
- 기술적 지표별 분포 막대 차트

2. Live Prediction

목적: 실시간 데이터로 즉시 예측

주요 기능:

- Upbit API에서 실시간 200시간 데이터 수집
 - 기술적 지표 자동 계산
 - SVM 모델로 1시간 후 가격 방향 예측
 - 클래스별 확률 분포 표시
-

3. Manual Prediction

목적: 사용자 입력 데이터로 예측

주요 기능:

- 개별 입력: OHLCV + 기술적 지표 직접 입력
 - 일괄 예측: CSV 파일 업로드 후 일괄 예측
 - 예측 결과 다운로드
-

4. Dataset Explorer

목적: 전체 데이터셋 탐색 및 분석

주요 기능:

- 인스턴스 필터링 (클래스별, 날짜별)
 - 속성 분포 시각화 (히스토그램, 박스플롯)
 - CSV 다운로드
-

5. Chart Image Analysis

목적: 차트 이미지 분석 (실험적 기능)

주요 기능:

- 차트 스크린샷 업로드
 - 색상 분석으로 트렌드 감지
 - 간단한 패턴 인식
-

6. Historical Analysis

목적: 특정 기간 데이터 분석

주요 기능:

- 날짜 범위 선택
 - 캔들스틱 차트 표시
 - 기간별 통계 (평균, 최고, 최저 가격)
-

7. WEKA Analysis

목적: WEKA 스타일 데이터마이닝 분석

Tab	기능	알고리즘
Classification	분류 분석	NB, DT, RF, SVM
Decision Tree	의사결정나무 시각화	J48 (CART)
Clustering	군집 분석	K-Means (k=3)
Association Rules	연관규칙 마이닝	Apriori
ANOVA	알고리즘 성능 비교	One-Way ANOVA

8. Model Performance

목적: 모델 성능 비교 및 분석

주요 기능:

- 4개 알고리즘 정확도 비교
- Learning Curve 시각화 (10-Fold CV)
- 95% 신뢰구간 표시
- 최적 모델 선택 근거 제시

4. Data Mining Methods

분석 방법론

1. Classification (분류)

목적: 새로운 인스턴스의 클래스를 예측

사용 알고리즘:

Algorithm	Description	특징
Naive Bayes	베이즈 정리 기반 확률적 분류	빠른 학습, 독립성 가정
Decision Tree (J48)	규칙 기반 트리 구조 분류	해석 용이, 과적합 위험
Random Forest	다수의 결정트리 앙상블	높은 정확도, 과적합 방지
SVM (RBF)	최적 결정 경계 탐색	고차원에 강함, 최고 성능

평가 지표:

- Accuracy (정확도)
- Precision, Recall, F1-Score
- Cross-Validation (10-Fold)

2. Learning Curve (학습곡선)

목적: 학습 데이터 크기에 따른 모델 성능 변화 분석

방법:

- 10%, 20%, ..., 100% 학습 데이터로 모델 학습
- 10-Fold Cross Validation으로 성능 측정
- 표준편차로 안정성 평가

해석:

- 학습곡선이 수렴하면 충분한 데이터
- 학습/검증 점수 차이가 크면 과적합

3. Performance Confidence Interval (성능 신뢰구간)

목적: 모델 성능의 신뢰 범위 추정

방법:

- 10-Fold Cross Validation 수행
- 각 Fold의 정확도 수집
- 평균 및 표준편차 계산
- 95% 신뢰구간: $\text{평균} \pm 1.96 \times \text{표준편차}$

해석:

"SVM 모델의 정확도는 95% 신뢰수준에서 64% ~ 74% 범위입니다."

4. ANOVA (분산분석) - 알고리즘 성능 비교

목적: 4개 알고리즘(SVM, RF, NB, DT) 간 성능 차이가 통계적으로 유의미한지 검정

데이터 수집 방법:

1. Learning Curve를 그려 최적 훈련 크기(80%)를 선정
2. 최적 훈련 크기(80%)에서 각 알고리즘을 **10번 반복 실행** (10-Fold CV)
3. 각 알고리즘마다 10개의 정확도 측정값 수집

ANOVA 변수:

- $k = 4$ (알고리즘 수)
- $n = 10$ (측정 횟수 = 10-Fold CV)
- 자유도: $df_1 = k-1 = 3$, $df_2 = k(n-1) = 36$

해석:

- $F \text{ 통계량} > F \text{ 임계값}$: 알고리즘 간 성능 차이가 **통계적으로 유의미**
- $F \text{ 통계량} \leq F \text{ 임계값}$: 차이가 우연에 의한 것일 수 있음

5. Clustering (군집분석)

목적: 유사한 인스턴스들을 그룹화

알고리즘: K-Means (k=3)

- 3개 클러스터로 시장 상황 분류
- 각 클러스터의 중심(Centroid) 분석
- 클러스터별 특성 파악

6. Association Rules (연관규칙)

목적: 속성 간 연관 패턴 발견

알고리즘: Apriori

주요 지표:

- **Support:** 규칙이 전체 데이터에서 나타나는 빈도
- **Confidence:** 선행 조건 발생 시 결과가 나타날 확률
- **Lift:** 규칙의 유용성 (1보다 크면 유의미)

예시:

```
"IF ma_cross=golden AND volume_spike=high THEN price_direction=UP (Confidence: 75%, Lift: 2.1)"
```

5. Installation & Academic Purpose

Prerequisites

```
Python 3.9 or higher  
pip (Python package manager)
```

Installation Steps

```
# 1. Clone repository  
git clone https://github.com/Jeong-Ryeol/Bitcoin-Price-Prediction-System.git  
cd Bitcoin-Price-Prediction-System  
  
# 2. Create virtual environment  
python3 -m venv venv  
source venv/bin/activate # On Windows: venv\Scripts\activate  
  
# 3. Install dependencies
```

```
pip install -r requirements.txt

# 4. Run the complete pipeline
python3 run.py

# 5. Launch web application
streamlit run app.py
```

Academic Purpose

이 프로젝트는 데이터마이닝 과목의 과제로 진행되었습니다.

학습 목표

- 실제 금융 데이터 수집 및 전처리
- 시계열 데이터 분석 및 특성 추출
- WEKA 데이터마이닝 도구 활용
- 다양한 분류 알고리즘 비교 및 평가
- 웹 기반 대시보드 개발

WEKA 요구사항 충족

요구사항	조건	본 프로젝트	충족
Instances	100개 이상	9,000개+	O
Attributes	4개 이상	9개	O
Classification	분류 분석	SVM, RF, DT, NB	O
Clustering	군집 분석	K-Means	O
Association	연관규칙	Apriori	O
Learning Curve	학습곡선	10-Fold CV	O
ANOVA	분산분석	One-Way ANOVA	O

Disclaimer

이 시스템은 교육 목적으로만 제작되었습니다. 실제 투자 결정에 사용해서는 안 됩니다. 과거 데이터는 미래 수익을 보장하지 않으며, 암호화폐 투자는 높은 리스크를 동반합니다.

Developer

Jeong Won Ryeol Department of Computer Science and Engineering

GitHub: <https://github.com/Jeong-Ryeol>

Data Mining Project 2025